

Laporan Praktikum Minggu Ke-5 Kontrol Cerdas

Minggu ke-5

Nama : Fatmawati Tia Pratama Putri
NIM : 224308056
Kelas : TKA 7C
Akun Github (Tautan) : <https://github.com/fatmawati25>

1. Judul Percobaan

Deep Reinforcement Learning untuk Kontrol Kompleks

2. Tujuan Percobaan

Tujuan dari percobaan pada praktikum kali ini, sebagai berikut:

- Memahami konsep Deep Reinforcement Learning (DRL) dalam kontrol sistem kompleks.
- Mengimplementasikan Deep Q-Network (DQN) untuk kontrol otomatis.
- Menganalisis performa DRL dibandingkan dengan metode kontrol konvensional.
- Menggunakan GitHub untuk version control dan dokumentasi praktikum.

3. Landasan Teori

Deep Reinforcement Learning (DRL) adalah subbidang dari Machine Learning yang menggabungkan dua teknik utama Reinforcement Learning (RL) dan Deep Learning. DRL menciptakan sebuah sistem Artificial Intelligence (AI), atau yang disebut agen, yang belajar membuat keputusan optimal melalui interaksi coba-coba dengan lingkungannya, dengan kemampuan tambahan untuk memproses data berdimensi tinggi dan mengenali pola kompleks berkat penggunaan jaringan saraf tiruan mendalam (deep neural networks). Dalam istilah sederhana, bayangkan DRL sebagai sebuah proses pembelajaran di mana sebuah agen belajar untuk berinteraksi dengan lingkungannya. Agen akan diberikan *reward* atau hukuman berdasarkan tindakan yang diambilnya. Dengan mempelajari pola dari *reward* dan hukuman ini, agen akan belajar untuk membuat keputusan yang lebih baik di masa depan.

Deep Reinforcement Learning (DRL) telah menunjukkan potensinya dalam berbagai bidang. Berikut adalah beberapa contoh aplikasinya:

1. Robotika dan Kontrol: DRL melatih robot untuk melakukan tugas kompleks dalam lingkungan yang tidak terstruktur. Contohnya, DRL digunakan untuk mengajarkan robot berjalan, menggenggam objek, dan bernavigasi di lingkungan baru.

2. Permainan: DRL telah mencapai kesuksesan luar biasa dalam menguasai permainan kompleks. AlphaGo, program yang dikembangkan oleh DeepMind, berhasil mengalahkan juara dunia Go menggunakan DRL.

3. Pengendalian Lalu Lintas: DRL dapat mengoptimalkan sistem kontrol lalu lintas untuk mengurangi kemacetan dan meningkatkan efisiensi. Algoritma DRL dapat mempelajari pola lalu lintas dan menyesuaikan waktu lampu lalu lintas secara real-time.

4. Keuangan: DRL dapat digunakan untuk mengembangkan strategi perdagangan algoritmik yang canggih. Algoritma DRL dapat mempelajari tren pasar dan membuat keputusan investasi yang optimal.

5. Kesehatan: DRL memiliki potensi besar dalam perawatan kesehatan. DRL dapat digunakan untuk menemukan dosis obat yang optimal, mempersonalisasi rencana perawatan, dan mendiagnosis penyakit dengan menganalisis data medis.

Deep Reinforcement Learning (DRL) menawarkan sejumlah keuntungan signifikan dibandingkan dengan metode pembelajaran mesin tradisional. Kemampuannya untuk belajar dari interaksi langsung dengan lingkungan membuka peluang. Salah satu keuntungan utama DRL adalah kemampuannya dalam menangani data yang kompleks dan tidak terstruktur, seperti gambar, video, dan teks. DRL juga menawarkan efisiensi dalam hal eksplorasi dan pengambilan keputusan. Dengan belajar dari kesalahannya sendiri, agen DRL dapat menemukan solusi optimal tanpa membutuhkan instruksi eksplisit untuk setiap skenario yang mungkin terjadi.

Pelatihan model DRL bisa sangat kompleks dan membutuhkan sumber daya komputasi yang besar. Selain itu, menentukan fungsi reward yang tepat bisa menjadi rumit, terutama untuk tugas-tugas yang kompleks. Tantangan lainnya

adalah memastikan keamanan dan keandalan sistem DRL. Karena agen DRL belajar secara mandiri, terdapat risiko perilaku yang tidak diinginkan atau bahkan berbahaya jika tidak dirancang dan dilatih dengan hati-hati.

DQN adalah algoritma yang menggabungkan metode klasik **Q-Learning** dari Reinforcement Learning (RL) dengan kemampuan representasi fitur yang kuat dari **Deep Learning (Pembelajaran Mendalam)**, khususnya **Jaringan Saraf Tiruan (Neural Network)**. Tujuan utama DQN adalah untuk memungkinkan agen AI belajar bagaimana **memprediksi nilai Q** (expected return/hadiah akumulatif) untuk setiap aksi yang dapat diambil dalam setiap keadaan, terutama ketika ruang keadaan (*state space*) sangat besar atau berkelanjutan. DQN secara efektif mengubah Reinforcement Learning dari disiplin ilmu yang terbatas pada ruang keadaan kecil menjadi metode yang mampu menangani masalah persepsi dan kontrol skala besar di dunia nyata.

Deep Q-Network (DQN) menggunakan TensorFlow dan OpenAI Gym adalah proyek klasik dalam Deep Reinforcement Learning (DRL). Ini adalah kerangka kerja yang kuat untuk melatih agen AI agar dapat mengontrol simulasi. Pastikan Anda telah menginstal pustaka-pustaka penting ini:

- TensorFlow/Keras: Untuk membangun, melatih, dan menjalankan Jaringan Saraf Mendalam.
- OpenAI Gym: Menyediakan lingkungan simulasi standar untuk RL (misalnya, CartPole-v1 yang merupakan simulasi kontrol stabilisasi).
- NumPy: Untuk operasi numerik dan manipulasi data.

Perbedaan RL dan DRL:

Aspek	Reinforcement Learning (RL)	Deep Reinforcement Learning (DRL)
Representasi State	Tabel Q-Value (Q-Table)	Neural Network
Skala Problem	Terbatas (Discrete State)	Lebih luas (Continuous & Complex State)
Contoh Algoritma	Q-Learning, SARSA	Deep Q-Network (DQN), PPO, A3C

4. Diskusi

1. Apa kelebihan dan kelemahan DQN dibandingkan metode Q-Learning klasik?

- Kelebihan

1. Mampu Menangani Ruang Keadaan yang Besar/Kontinu

Q-Learning klasik menggunakan Tabel Q (Q-table) untuk menyimpan nilai. Metode ini tidak praktis (*intractable*) ketika jumlah keadaan () dan aksi () terlalu banyak (misalnya, jutaan keadaan), seperti pada *video game* atau robotika.

2. Pembelajaran *End-to-End* dari Data Mentah

DQN dapat belajar langsung dari data sensor mentah (misalnya, piksel layar *game* Atari), tanpa memerlukan *feature engineering* manual oleh manusia. Jaringan saraf secara otomatis menemukan fitur yang paling relevan untuk memprediksi hadiah di masa depan.

- Kekurangan

1. Terbatas pada Ruang Aksi Diskret

Algoritma DQN standar dirancang untuk memprediksi nilai Q untuk setiap aksi diskret yang mungkin. Jika aksi bersifat

kontinu (misalnya, sudut kemudi mobil atau dorongan robot), DQN tidak dapat secara langsung mencari aksi di seluruh ruang aksi kontinu. Ini membutuhkan modifikasi algoritma (seperti DDPG atau A2C/A3C).

2. Kebutuhan Komputasi Tinggi

Melatih Jaringan Saraf Mendalam (terutama yang dalam) membutuhkan daya komputasi yang jauh lebih besar dan waktu pelatihan yang jauh lebih lama dibandingkan dengan pembaruan sederhana pada *Q-table* dalam Q-Learning klasik.

3. Sensitif terhadap Hiperparameter dan Estimasi Berlebihan (*Overestimation*)

2. Bagaimana cara mengadaptasi DQN untuk kontrol sistem dinamis seperti drone atau robot industri?

Karena DQN standar hanya bekerja dengan aksi diskret, adaptasi utama berfokus pada memodifikasi arsitektur aksi atau beralih ke algoritma yang *policy-based* (berbasis kebijakan) yang lebih canggih.

- Menangani Ruang Aksi Kontinu

Sistem dinamis seperti drone (yang memiliki kontrol daya dorong dan sudut kemudi yang kontinu) atau robot industri (yang memiliki sendi bergerak kontinu) tidak dapat dikontrol hanya dengan aksi "kiri" atau "kanan". Ada dua cara utama untuk mengatasi hal ini:

1. Diskritisasi Aksi (*Action Discretization*)

Ini adalah cara paling sederhana untuk mengadaptasi DQN standar. Ambil rentang aksi kontinu yang mungkin (misalnya, daya dorong motor dari 0% hingga 100%) dan bagi menjadi sejumlah kecil aksi diskret yang relevan.

2. Beralih ke Algoritma Lain

Untuk kontrol sistem dinamis yang akurat, sangat disarankan untuk beralih ke algoritma DRL yang dirancang untuk ruang aksi kontinu, yang merupakan evolusi dari konsep DQN: Deep Deterministic Policy Gradient (DDPG): Mirip dengan DQN karena menggunakan Jaringan Target dan *Experience Replay*, tetapi

DDPG melatih Jaringan Aktor (*Actor Network*) untuk mengeluarkan nilai aksi kontinu secara langsung, dan Jaringan Kritikus (*Critic Network*) untuk mengevaluasi aksi tersebut. Soft Actor-Critic (SAC): Algoritma modern yang menyeimbangkan eksplorasi dan eksploitasi secara efektif, menjadikannya salah satu algoritma *state-of-the-art* untuk kontrol robot yang mulus (*smooth*) dan efisien.

- Peningkatan Stabilitas dan Keamanan

Lingkungan nyata jauh lebih kompleks dan berisiko daripada simulasi *game*. Adaptasi ini sangat penting untuk robotika:

1. Input Data Sensor yang Kompleks

Sistem dinamis memiliki input keadaan yang terdiri dari data *real-time* dari berbagai sensor:

- Drone: Data dari IMU (percepatan, kecepatan sudut), GPS, Lidar/Kamera (jika ada).
- Robot Industri: Posisi sendi, torsi, *force feedback*, dan *visual input*.

Jaringan saraf harus dirancang untuk menangani input heterogen ini:

- Jaringan Saraf Konvolusi (CNN): Digunakan jika input keadaan adalah data visual (misalnya, robot menghindari rintangan menggunakan kamera).
- Jaringan *Feedforward* Dens (Dense Feedforward Networks): Digunakan untuk data numerik non-visual (misalnya, data IMU atau posisi sendi).

2. *Sim-to-Real Transfer* (Transfer Simulasi ke Nyata)

Model yang dilatih di simulasi (Gym) harus dapat bekerja di dunia nyata:

- Pelatihan di Simulasi: Latih agen secara ekstensif di lingkungan simulasi yang akurat secara fisik (misalnya, Gazebo untuk robot, AirSim untuk drone) untuk mendapatkan kebijakan awal.

- *Domain Randomization*: Dalam simulasi, secara acak ubah parameter lingkungan (gesekan, massa, latensi sensor) sehingga agen tidak terlalu bergantung pada parameter simulasi yang spesifik. Ini membuat kebijakan yang dihasilkan lebih kuat (*robust*) saat diterapkan ke perangkat keras fisik.

3. Pembelajaran Berbasis Hadiah yang Aman (*Safe Reward Engineering*)

Merancang fungsi hadiah (Reward Function) sangat krusial. Hadiah harus mendorong kinerja sekaligus mencegah perilaku berbahaya:

- Hadiah Negatif untuk Kesalahan: Selain hadiah untuk mencapai tujuan, berikan hukuman negatif yang besar untuk kegagalan atau keadaan yang tidak aman (misalnya, menabrak tembok, sudut kemiringan drone terlalu ekstrem).
- Penalti Kontrol: Tambahkan hukuman kecil untuk penggunaan energi yang berlebihan (perubahan aksi yang besar atau cepat) untuk memastikan aksi kontrol yang mulus dan meminimalkan keausan robot.



5. Assignment



Pada praktikum ini dilakukan penerapan Deep Reinforcement Learning untuk Kontrol Kompleks. Membahas konsep Deep Reinforcement Learning (DRL) dan implementasinya, khususnya menggunakan Deep Q-Network (DQN), serta menunjukkan hasil pengamatan dari aplikasi visi komputer (Computer Vision/VS Code) yang terkait. Didefinisikan dengan jelas sebagai gabungan Reinforcement Learning (RL) dan Deep Learning. DRL menggunakan jaringan saraf mendalam (*deep neural networks*) untuk memproses data kompleks dan memungkinkan agen belajar membuat keputusan optimal melalui interaksi *coba-coba* dengan lingkungan (mendapatkan *reward* atau hukuman).



Bagian hasil pengamatan (Data dan Output Hasil Pengamatan) menunjukkan keberhasilan penerapan model *Computer Vision* (meskipun tidak secara langsung DQN, ini menunjukkan kapabilitas AI/DL):



- **Hand Detection:** Model berhasil mendeteksi secara akurat tangan tunggal (kanan dan kiri).
- **Multi-Hand Detection:** Sistem menunjukkan kapabilitas luar biasa dengan melacak **dua bahkan hingga tiga tangan** dalam satu *frame*.
- Tangan Kanan dan Kiri: Akurat dalam mendeteksi dua tangan dan mengklasifikasikannya (kiri/kanan) dengan estimasi pose 21 *keypoints*.
- Tiga Tangan: Berhasil melacak tiga objek tangan dalam kondisi *overlapping*, membuktikan **robustness** model.
- **Person Detection:** Sistem berhasil mendeteksi dan mengestimasi pose seluruh tubuh manusia (termasuk saat berpose unik atau balik badan), ditandai dengan kotak pembatas dan *keypoints* sendi.

6. Data dan Output Hasil Pengamatan

No	Keterangan	Hasil Percobaan
1	Hasil dari Hand Detection – Tangan Kanan Model tersebut berhasil mendeteksi lokasi tangan, mengidentifikasi sebagai tangan kanan, mengukur kepercayaan deteksi, dan memetakan 21 titik kunci (<i>keypoints</i>) penting pada struktur tangan untuk tujuan pelacakan atau pengenalan gerakan.	
2	Hasil dari Hand Detection – Tangan Kiri	

3	Hasil dari Hand Detection – Tangan Kanan dan Kiri Secara akurat mendeteksi lebih dari satu tangan dalam satu <i>frame</i> video. Mengidentifikasi secara spesifik apakah tangan yang terdeteksi adalah tangan kiri atau tangan kanan. Melakukan estimasi pose tangan dengan memetakan 21 sendi utama (<i>keypoints</i>) pada masing-masing tangan, sebuah kemampuan krusial untuk aplikasi seperti pengenalan bahasa isyarat, interaksi <i>gesture</i> (gerakan), atau kontrol robot.	
4	Hasil dari Multi Hand Detection – Tangan Kanan, Kiri, dan Tangan Kanan Orang Lain Melacak tiga objek tangan dalam kondisi kerumitan visual (overlapping) di satu <i>frame</i>. Dengan sukses mengklasifikasikan setiap tangan yang terdeteksi sebagai "Right Hand" atau "Left Hand". Melakukan pemetaan 21 titik kunci (<i>keypoints</i>) secara <i>real-time</i> pada setiap tangan, bahkan pada tangan yang posisinya agak tersembunyi atau di tepi <i>frame</i>.	

5	Hasil dari Hand Detection with Bounding Box – Tangan Kiri	 A person wearing a hijab and glasses is shown from the chest up. Their left hand is raised, and a green bounding box is drawn around it. The text "Left Hand" is written in green above the box. The background is a workshop with various electronic components and tools.
6	Hasil dari Hand Detection with Bounding Box – Tangan Kanan	 A person wearing a hijab and glasses is shown from the chest up. Their right hand is raised, and a green bounding box is drawn around it. The text "Right Hand" is written in green above the box. The background is a workshop with various electronic components and tools.
7	Hasil dari Hand Detection with Bounding Box – Tangan Kanan dan Kiri	 A person wearing a hijab and glasses is shown from the chest up. Both their left and right hands are raised, and green bounding boxes are drawn around each. The text "Left Hand" and "Right Hand" are written in green above their respective boxes. The background is a workshop with various electronic components and tools.
8	Hasil dari Person Detection Seluruh tubuh subjek dikelilingi oleh kotak besar berwarna hijau yang menandai area deteksi. Di atas kotak, terdapat label "Person" berwarna putih, yang mengonfirmasi bahwa objek yang terdeteksi adalah manusia. Terdapat serangkaian titik kunci, ditandai dengan lingkaran kecil berwarna merah (dan mungkin biru muda di bagian tengah), yang	 A person wearing a hijab and glasses is shown from the waist up. A large green bounding box is drawn around their entire body. The text "Person" is written in green above the box. The background is a workshop with various electronic components and tools.

	ditempatkan pada sendi-sendi utama tubuh.	
9	Hasil dari Person Detection	
10.	Hasil dari Person Detection Balik Badan	

7. Kesimpulan

Berdasarkan percobaan yang dilakukan dapat disimpulkan bahwa:

1. Berhasil mempraktikkan konsep Deep Reinforcement Learning (DRL) sebagai gabungan RL dan Deep Learning, yang esensial untuk mengendalikan sistem kompleks.
2. Algoritma Deep Q-Network (DQN) adalah solusi vital yang mengatasi keterbatasan Q-Learning klasik pada ruang keadaan yang besar (seperti input gambar atau video) dengan menggunakan Jaringan Saraf sebagai aproksimator fungsi.
3. Percobaan visualisasi menunjukkan kapabilitas kuat dari model Deep Learning dalam melakukan Multi-Hand Detection dan Person

Pose Estimation, berhasil melacak secara akurat hingga tiga tangan dan pose tubuh dengan *keypoints* yang kompleks.

8. Saran

Untuk memperkuat pemahaman konsep dan implementasi, disarankan agar praktikum berikutnya berlanjut pada tahap implementasi *end-to-end* DQN yang sebenarnya menggunakan lingkungan simulasi standar seperti OpenAI Gym (misalnya, *CartPole-v1* atau *Acrobot*) untuk memvisualisasikan kurva pembelajaran dan membandingkan performa *reward* dari waktu ke waktu. Selanjutnya, praktikan perlu menjelajahi algoritma DRL berbasis kebijakan (seperti DDPG atau SAC) untuk memahami adaptasi kontrol pada ruang aksi kontinu yang relevan dengan robotika dan drone. Terakhir, tingkatkan kedalaman analisis dengan melakukan eksperimen sederhana terhadap Fungsi Hadiah (*Reward Function*) untuk memperjelas tantangan dan pentingnya *Safe Reward Engineering* dalam desain sistem DRL yang andal dan aman di dunia nyata.

9. Daftar Pustaka

- <https://soaltekno.lokercepat.id/pengertian-deep-reinforcement-learning/>
- Pratama, D. A. S. (2024). Pengembangan Kontrol Adaptif untuk Kendaraan Otonom dengan Studi Kasus pada Mobil Elektrik Berbasis Deep Reinforcement Learning.
- Ridho Amanda Putra. (2024). ANALISIS DEEP Q-NETWORK (DQN) UNTUK SIMULASI LAMPU LALU LINTAS ADAPTIF BERDASARKAN WAKTU TUNGGU KENDARAAN.